

Trabalho de Conclusão de Curso

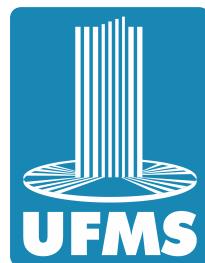
Sistema Automático de Calibração de
Cores para a Equipe de Futebol De
Robôs Cedro

Jasane Schio

Orientação: Prof. Dr. Gedson Faria

Coorientação: Prof. Me. Angelo Darcy

Área de Concentração: Sistemas de Informação, Visão Computacional



Sistema de Informação
Universidade Federal de Mato Grosso do Sul
30 de Setembro de 2015

Sistema Automático de Calibração de Cores para a Equipe de Futebol De Robôs Cedro

Coxim, 01 de Outubro de 2015.

Banca Examinadora:

- Prof. Me. Angelo Darcy Molin Brun (CPCX/UFMS)
- Prof. Dr. Gedson Faria (CPCX/UFMS) - Orientador
- Prof. Gustavo Yoshio Maruyama (IFMS)
- Prof. José Alves de Sousa Neto(CPCX/UFMS)

Resumo

Para serem identificadas as tiras a serem calibrados no campo, utilizou-se a técnica Algoritmo de Canny, que faz a detecção das bordas presentes na imagem. Após serem detectadas as bordas fez-se então uma analise para identificar quais bordas pertencem à mesma tira, é somente após essa analise que as tiras são identificadas pela junção de suas respectivas bordas. Assim que identificadas, cada um dos tiras foi analisado de acordo com o estudo das cores para assimilar a qual cor a mesma pertencia, e seus valores comparados para identificar se esta seria um limite do intervalo da cor a qual pertence.

Abstract

Conteúdo

Lista de Figuras	7
1 Introdução	9
1.1 Contexto	9
1.2 Trabalhos Correlatos	9
1.2.1 Calibra	10
1.2.2 VSS-Vision	10
1.3 Motivação e Justificativa	11
1.4 Objetivos	12
1.5 Organização da Trabalho	13
2 Fundamentação Teórica	14
2.1 Processamento de Imagens	14
2.1.1 Detecção de Objetos	14
2.1.2 Detecção de Bordas	15
2.2 Cores	16
2.3 Futebol de Robôs	18
3 Desenvolvimento	20
3.1 Tecnologias Usadas	20
3.2 Projeto	21
3.2.1 Organização do Projeto	21
3.2.2 Classes	21
3.3 O Sistema	23
3.3.1 1 ^a Etapa - Configuração de Câmera	23
3.3.2 2 ^a Etapa - Reconhecimento de Fundo	25

3.3.3	3 ^a Etapa - Extração dos Objetos do Fundo	26
3.3.4	4 ^a Etapa - Detecção e validação de Objetos	26
3.3.5	5 ^a Etapa - Classificação do Pixel	27
3.3.6	6 ^a Etapa - Gerar Arquivo de Cores	28
4	Testes e Resultados	29
4.1	Calibração	29
4.2	Testes	31
4.2.1	Cores Comuns	32
4.2.2	Cores Com Problemas Conhecidos	36
5	Conclusão	40
5.1	Principais Considerações	40
5.2	Trabalhos Futuros	41
Referências Bibliográficas		42

Lista de Figuras

1.1	Sistema Calibra, FEI(Penharbel et al., 2004)	10
1.2	Sistema de calibracao, SIRLab(da Rosa, 2015)	10
1.3	Nova interface do sistema de calibração da SIRLab(SIRLab,)	11
1.4	Atual Sistema de calibração da SIRLab(SIRLab,)	11
2.1	Detecçao de Borda com Algoritmo de Canny(Saini et al., 2013)	16
2.2	Universo de cores estabelecido pelo CIE.	17
2.3	Exemplo dos espaços de cores RGB E CMY.	17
2.4	Exemplo do Modelo de Cor RGB. Horvath(Horvath,)	18
2.5	Exemplo do Modelo de Cor HSV, Horvath(Horvath,)	18
3.1	Organização das pastas do projeto	21
3.2	Diagrama de Fluxo	23
3.3	Configuração de Camera	24
3.4	Configuração de Camera	25
3.5	Geração de Máscara	26
4.1	Imagen do fundo com a seleção de campo	29
4.2	Objetos dispostos no campo para calibração	30
4.3	Divisão do campo em quinze partes nomeadas alfabeticamente.	31
4.4	Disposição de cada parte quanto as cores	31
4.5	Campo após terem sido dispostas as cores	31
4.6	Imagen somente com os objetos dentro do intervalo do valor da cor amarela	32
4.7	Imagen somente com os objetos dentro do intervalo do valor da cor azul . .	33
4.8	Imagen somente com os objetos dentro do intervalo do valor da cor verde . .	34
4.9	Imagen somente com os objetos dentro do intervalo do valor da cor rosa . .	35

Capítulo 1

Introdução

1.1 Contexto

Como uma prova dos crescentes avanços robóticos nas ultimas décadas, em 1997 foi estabelecida a FIRA(FIRA, a), Federation of International Robot-soccer Association. Com o intuito de promover o desenvolvimento nas áreas de multi-agentes autonomos e cooperação entre robôs, bem como pesquisas e estudos relacionados a mecatrônica, processamento de imagens e robótica(FIRA, b). O Futebol de Robôs tem sido uma das principais áreas de foco por ser um domínio complexo, exigindo autonomia do sistema e solução de problemas em tempo real(Costa and Pegoraro, 2000).

Porém a maneira como um técnico de futebol passa as informações para seus jogadores em campo, cara à cara, torna-se indisponível no futebol de robôs, já que neste ambiente tais informações precisam ser passadas via comunicação de dados, cada um dos robôs se difere do outro por obter um IP único. Para saber qual dos robôs possui cada IP, eles possuem marcadores com duas cores, uma cor designando o time a qual o robô pertence e outra que o identifica de maneira única dentro de sua equipe. A estratégia, de cada equipe, então detecta os marcadores de cor utilizando técnicas de visão computacional e decide a partir da posição dos robôs, qual atitude será tomada em campo.

Acontece que para identificar cada uma das cores é necessário que se faça o que é chamado de calibração. A calibração de cores ocorre para designar o intervalo de valores que corresponde a cada cor naquele determinado momento. Intervalos de cores podem ser pré definidos, no entanto de acordo com a iluminação presente na imagem esses valores tendem a ser alterados, por isso a calibração em cada jogo se faz necessária.

1.2 Trabalhos Correlatos

Para o tema específico deste trabalho, calibração de intervalo de cores para times de futebol de robôs da categoria IEEE Very Small Size Soccer, não foram encontrados trabalhos relacionados, porém foram encontrados Team Discription Papers e descrições de sistemas usados pelos times(??).

1.2.1 Calibra

O Centro Universitário da FEI(Penharbel et al.,) utiliza em sua equipe Y04 um sistema denominado CALIBRA(Penharbel et al., 2004). Desenvolvido para sistemas Linux e com Graphical User Interface(Penharbel et al., 2004), o sistema de calibração possui um módulo chamado de MainWindow, que é responsável pela configuração de brilho, cor e contraste da imagem adquirida pela câmera e gera um arquivo que é analizado na hora da criação das cores padrão(Penharbel et al.,), as cores-padrão são definidas como intervalos no espaço de cores HSI(Penharbel et al.,). Apesar da descrição do sistema, o modo como ocorre a calibração não é descrito pela documentação.



Figura 1.1: Sistema Calibra, FEI(Penharbel et al., 2004)

1.2.2 VSS-Vision

Em 2015, Rosa(da Rosa, 2015) descreveu sobre a equipe de futebol de robôs Very Small Size, do Laboratório de Sistemas Inteligentes e Robótica, SIRLab(Faeterj-Petrópolis), e o sistema de visão computacional da equipe, durante a competição do ano de 2014, que abrange inclusive a parte de calibração.

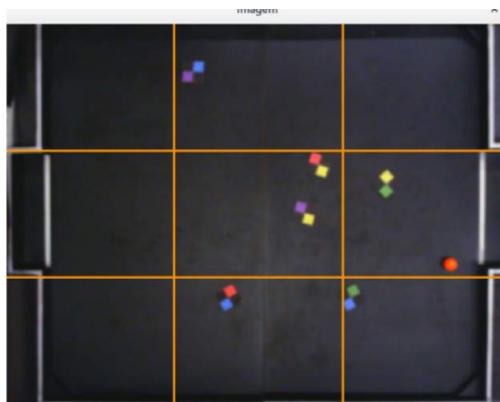


Figura 1.2: Sistema de calibracão, SIRLab(da Rosa, 2015)

Rosa menciona que a calibração de cores é feita calibrando obrigatoriamente laranja, amarelo e azul, e então as outras cores referentes aos jogadores em campo. Como visto na

Figura 1.2 a imagem da câmera é dividida em nove cantos, e para calibrar a cor o usuário deve clicar em cima da cor que gostaria de ser calibrada, assim salvando um intervalo de cor tratado como RGB máximo e o mínimo daquela cor , a medida que vão havendo os cliques o sistema verifica para cada atributo se ele é maior que o atributo máximo salvo ou menor que mínimo salvo, caso seja, o mesmo assume o lugar de menor ou maior e esse processo deve ser feito em cada um dos nove cantos da imagem(da Rosa, 2015). O desenvolvimento do sistema utiliza para processamento de imagens a biblioteca OpenCV e para telas interativas a biblioteca ImGui.

O atual sistema de visão computacional do SIRLab passou por algumas mudanças desde 2015 e conta com uma interface e metodo de calibração diferentes(SIRLab,). Como disponível no repositorio online do Laboratorio, o atual sistema de calibração de cores utiliza o espaço de cores HSV, no lugar do RGB(da Rosa, 2015). A antiga interface do sistema, feita inicialmente em ImGui deu lugar a nova, desenvolvida em Qt, como mostra a Figura 1.3.

O método de calibração de cores também foi modificado, o sistema possibilita a calibragem de 8 cores, Laranja, Amarelo, Azul, Vermelho, Verde, Rosa, Roxo, Marrom(SIRLab,). Após o usuário escolher uma cor para calibrar o mesmo deve encontrar um intervalo de cor, no espaço de cores HSV, que represente-a. Ao clicar na tela com o botão direito o sistema da um zoom na área para ajuste fino. A Figura 1.4 demonstra o novo método de calibração.

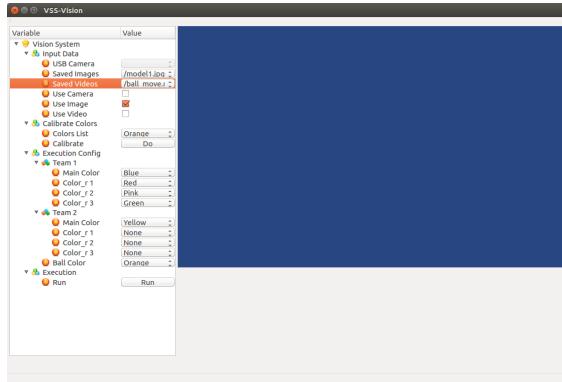


Figura 1.3: Nova interface do sistema de calibração da SIRLab(SIRLab,)

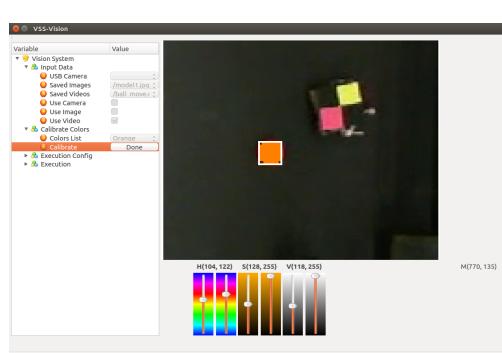


Figura 1.4: Atual Sistema de calibração da SIRLab(SIRLab,)

1.3 Motivação e Justificativa

Em 2015 surgiu a equipe Cedro, equipe de futebol de robôs categoria IEEE Very Small Size Soccer da UFMS Campus Coxim. Já em seu primeiro ano a equipe participou da Competição Latino Americana de Robótica, competição cuja qual tive a oportunidade de participar como membro da equipe. Como minha primeira vez em um evento deste âmbito, fiz algumas observações sobre as equipes e as partidas, a principal foi quanto a calibração de cores. De forma informal, todo jogo possue um *aquecimento* de 20 minutos, tempo esse que a maioria das equipes utilizada deste tempo para fazer a calibração de cores. Na equipes que observei, o processo de calibração foi feita de forma manual com uma interface muito semelhante ao desenvolvido por Kyle Hounslow(Hounslow,). Em algumas equipes, inclusive foi desenvolvido um novo modelo de cores, como é o caso da POTI/UFRN(Martins et al., 2007).

Foi estudado o problema da calibração de cores para competição de futebol de robôs

categoria IEEE Very Small Size Soccer, na qual a calibração de cada uma das cores em campo acaba se tornando um processo exaustivo por ter de ser feito um a um, cerca de 5 minutos para cada cor. Geralmente o tempo de preparo inicial antes de cada jogo é de 20 minutos, tempo que acaba sendo gasto praticamente inteiro no processo de calibração. Se o processo de calibração fosse automatizado, e assim reduzido, haveria mais tempo para ser usado em melhorias técnicas, hardware dos robôs com problemas, melhorias na estratégia de jogo ou resolvendo problema de comunicação. Devido ao problema citado percebeu-se o benefício de se desenvolver um sistema autônomo de registro do valores HSV que faça a definição de intervalos de cores baseando-se nos objetos em campo, os identificando de forma automática, assim diminuindo o alto tempo gasto na calibração de cores

1.4 Objetivos

Neste trabalho tem-se por objetivo principal automatizar o sistema de identificação de objetos coloridos em imagens provenientes de uma câmera em imagens de tempo real, fazendo a calibração dos valores HSV identificando seus limites mínimos e máximos. Para desenvolver um sistema que supra essas necessidades, foram propostos os seguintes objetivos específicos:

- Estudar e implementar a detecção automática dos objetos em campo;
- Estudo de cores para identificação de intervalos de cores dentro da biblioteca OpenCV;
- Categorização das cores dos objetos identificados dentro dos intervalos estudados;
- Testar o sistema proposto para identificação de cores.

1.5 Organização da Trabalho

Este trabalho está dividido em cinco capítulos, incluindo esta introdução como capítulo inicial. No segundo capítulo encontra-se a fundamentação teórica, conteúdo informações sobre processamento de imagens referente à detecção de objetos e cores e uma breve descrição sobre o futebol de robôs. No terceiro capítulo encontra-se todo o desenvolvimento do projeto, suas classes, a descrição das tecnologias utilizadas no projeto, e a descrição do processo de calibração. No quarto capítulo são apresentados os testes e discutidos os resultados obtidos. No quinto capítulo são feitas as conclusões do trabalho, bem como expostas melhorias que possam vir a ser implementadas em trabalhos futuros.

Capítulo 2

Fundamentação Teórica

2.1 Processamento de Imagens

O processamento de imagens é a técnica de trabalhar com uma imagem e seus elementos visando retirar suas informações(Albuquerque and Albuquerque, 2001). Além da retirada de informações, o processamento de imagens também inclui a modificação ou melhoria da imagem por meio de redução de ruído, melhoria no contraste, segmentações da imagem entre outras técnicas. Dentre tipos de processamento de imagens existem, Gonzalez(Gonzalez and Woods, 2008) os define como: aplicações de ações primitivas de modificação de imagem, esta caracterizada por seu resultado final ser também uma imagem semelhante a imagem inicial porém modificada(Low-Level-Process), divisão de imagem em regiões e alguns tipos de reconhecimento e classificação de objetos, caracterizada por seu resultado final ser muitas vezes apenas regiões ou informações da imagem inicial(Mid-Level-Process), e o mais sensorial de todos que é a análise de objetos usando funções cognitivas associadas a visão computacional, essa usa informações relevantes para o reconhecimento de objetos(Higher-Level-Process). Uma vez que o objetivo deste trabalho é reconhecer os objetos em campo para calibrá-los, usaremos técnicas de retirada de informações e regiões. Explicaremos sobre as técnicas usadas nas subseções seguintes.

2.1.1 Detecção de Objetos

A detecção de objetos pode ser considerada uma técnica herdada do reconhecimento de padrões, da área de aprendizado de máquina, esta consiste em separar objetos por categorias de acordo com uma ou mais características específicas. Quando essa técnica se junta ao processamento de imagens, estas características são acentuadas em um determinado objeto dentro da imagem para assim este se destacar, tornou-se possível a detecção de objetos em imagens, que dentro do campo de visão computacional é uma das áreas que mais obtém a atenção de pesquisadores. O primeiro Framework de métodos que usam base de dados categorizando uma ou mais características de um objetos para fazer o reconhecimento através de aprendizado foi apresentado em 2001 por Viola e Jones(Viola and Jones, 2001). Desde o framework de Viola e Jones até os dias atuais muitos métodos e teorias para detecção já foram propostos e implementados, como detecção de faces utilizando um classificador de redes neurais na intensidade de padrões de uma imagem, support vector machine para localizar

rostos humanos e carros(Nascimento, 2007), análise de componentes principais, análise independente de componentes, fatoração de matriz não-negativa, análise discriminativa linear, boosting(Roth and Winter, 2008), além da classificação binaria, que considera a detecção do objeto em tamanho fixo apenas variando na posição na imagem(Amit and Felzenszwalb, 2014).

2.1.2 Detecção de Bordas

Para um objeto poder ser detectado por algum método de detecção a imagem passa por um processo de segmentação. A segmentação pode ser dita como o processo de divisão da imagem em objetos(Gonzalez and Woods, 2008). De acordo com Wangenheim(WANGENHEIM, 2014) o processo de segmentação se baseia em dois conceitos: similaridade e descontinuidade. A descontinuidade é o processo onde se separa o fundo das partículas e estas umas das outras, através de linhas, bordas ou pontos. Já a similaridade é o processo onde os pixeis provenientes da descontinuidade são agrupados de acordo com a proximidade um dos outros para formar os objetos de interesse. De acordo com Canny(Canny, 1986) o processo de detecção de bordas é um processo simplificado que serve para diminuir drasticamente o total de dados a serem processados e ao mesmo que o mesmo preserva informações valiosas sobre os objetos, este também é considerado um processamento de imagem de baixo nível, uma vez que age diretamente na imagem original apenas melhorando-a. É muito comum a ocorrência de ruídos quando se trata da detecção de bordas, e por sua vez para evitar esses ruídos é necessário a suavização da imagem antes de fazer a detecção. Vale(do Vale and Poz, 2002) lembra que a suavização possui pontos negativos como perda de informação e deslocamento de estruturas de feições proeminentes no plano da imagem. Além disso, existem diferenças entre as propriedades dos operadores diferenciais comumente utilizados, o que ocasiona bordas diferentes. Assim, como dito por Ziou e Tabbone citados por Vale(do Vale and Poz, 2002), se torna difícil encontrar um algoritmo que tenha bom desempenho em diferenciados contextos e capture os requisitos necessários aos estágios subsequentes do processamento. Quando se trata de detecção de bordas existem dois critérios(Canny, 1986) para essa detecção que devem ser levados em consideração, Taxa de Erro e Localização(do Vale and Poz, 2002).

Taxa de Erro É importante que as bordas contidas na imagem não sejam confundidas ou perdidas e ainda que não sejam detectadas bordas falsas. É necessário que o algoritmo de detecção de borda tenha uma baixa taxa de erro para que seja eficiente(WANGENHEIM, 2014, Canny, 1986, do Vale and Poz, 2002).

Localização A distância entre os pixels de borda encontradas pelo algoritmo e a borda atual deveriam ser o menor possível(WANGENHEIM, 2014).

Ao tentar aplicar esses dois critérios para desenvolver um modelo matemático para detecção de bordas sem a necessidade de base em regras preestabelecidas em seu artigo, *A Computational Approach to Edge Detection*, Canny percebeu que somente esses dois critérios não eram o suficiente para obter uma boa precisão da detecção de bordas. E então propôs um terceiro critério: Resposta.

Resposta Para contornar a possibilidade de mais de uma resposta para a mesma borda, ou seja o detector de bordas não deveria identificar múltiplos pixels de borda onde somente existe um único pixel(WANGENHEIM, 2014, Canny, 1986, do Vale and Poz, 2002).

Com o acréscimo do terceiro critério então nota-se que o processo de detecção de bordas de Canny mostrou-se bastante flexível, independente da origem da imagem utilizada(do Vale and Poz, 2002).

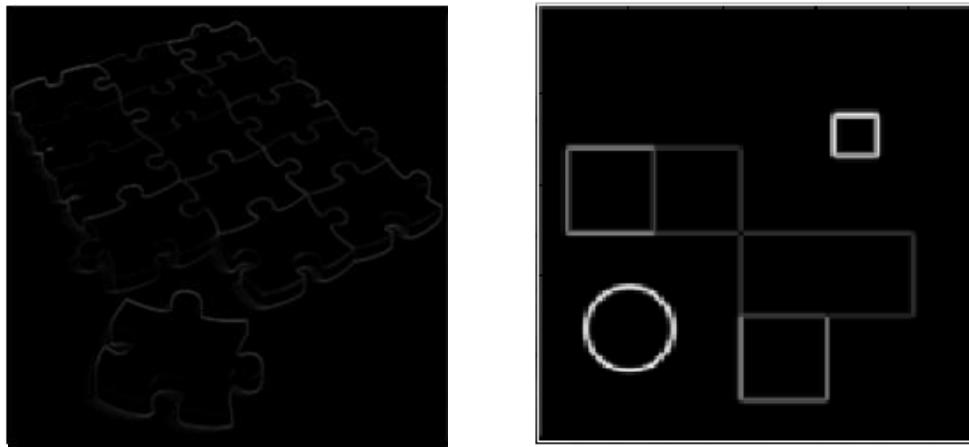


Figura 2.1: Detecçao de Borda com Algoritmo de Canny(Saini et al., 2013)

2.2 Cores

O olho humano é capaz de identificar cores mesmo com as mais diferentes interferências, luminosidade, tonalidade, intensidade, entre outras ações de agentes externos graças aos **cones** e **bastonetes**. Os bastonetes são os responsáveis por distinguirem tons de cinza e pela visão periférica e tem como característica serem sensíveis a baixo nível de luminosidade(Azevedo and A., 2003). Os cones, por sua vez, são sensíveis ao alto nível de iluminação e responsáveis pela percepção de cores(Azevedo and A., 2003). Segundo a teoria tricomática de Thomas Young e mais tarde estudada por Hermann von Helmholtz(Azevedo and A., 2003), a retina humana é formada por três tipos de fotopigmentos que seriam os três receptores de cor, ou seja respondiam ao comprimento de onda de apenas três cores: Vermelho, Verde e Azul. A informação obtida através do sistema visual humano é assimilada pelo cérebro humano e ligando a cor a sua aparência levando em consideração o aprendizado que obtivemos sobre a mesma, já para uma máquina cores são números, códigos, cada cor contém um código específico e cada uma de suas variâncias também. Para o nosso cérebro é muito fácil entender, exemplo, que o verde, verde lima, verde escuro são todos verde, apenas com tonalidades diferentes, já para o computador estas são: $(0,255,0)$, $(50,205,50)$, $(0,128,0)$, no padrão de cor RGB. Mas se for aplicado luminosidade nessas cores, por exemplo, elas ainda se tornam outras diferentes cores, um código diferente para cada luminosidade possível.

Para poder explicar as propriedades e comportamentos das cores em determinadas circunstâncias, surgiram os **Sistemas de cores**. Devido a complexidade existente em explicar todos os aspectos relacionados às cores são utilizados diversos sistemas para descrever as mais diferentes características das cores e sua percepção pelo ser humano(Azevedo and A., 2003). Dentro os sistemas mais conhecidos, estão o RGB, HSV E HSL, sistemas quais serão neste trabalho.

Segundo Azevedo(Azevedo and A., 2003) o universo de cores que podem ser reproduzidas por um sistema é chamado de **Espaço de Cores**. De acordo com Foley et. al citado por

Souto(Souto, 2003) espaço de cores é um sistema tridimensional de coordenadas, onde cada eixo refere-se a uma cor primária. A quantidade de cor primária necessária para reproduzir uma determinada cor, é atribuída a um valor sobre o eixo correspondente. O espaço de cores pode ser entendido como a quantidade de detalhamento, tonalidades de uma cor, dentro do espectro de cores de um determinado modelo de cor.

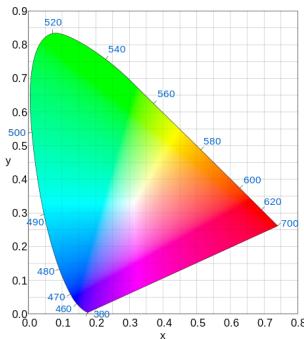


Figura 2.2: Universo de cores estabelecido pelo CIE.

Quando fez sua primeira experiência com a decomposição da luz em um prisma para obter cores Newton percebeu que não havia a cor branca. Ele tentou então misturar as sete cores que obteve para gerar a branca, sem sucesso. Para conseguir cobrir todas as alterações e características as cores em 1921 a Comissão Internacional de Iluminação(CEI)(Souto, 2003) definiu três primárias(X, Y e Z) que podem ser combinadas para formarem todas as cores e entendeu-se que existe duas formas de se obter cores: através da emissão ou reflexão de luz, espaços RGB e CMY respectivamente, Figura 2.2. Assim entendeu-se então porque em seu experimento Newton não obteve sucesso para gerar a cor branca, pois para gerar a cor branca é necessário a soma das três cores primárias azul, verde e vermelho, uma vez que seu experimento utilizava a reflexão e não emissão de cores.

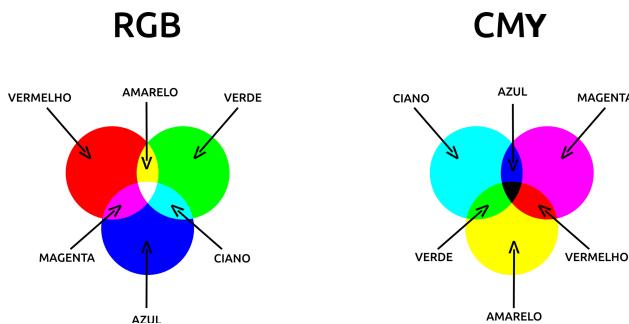


Figura 2.3: Exemplo dos espaços de cores RGB E CMY.

Para utilização prática de sistemas e espaços de cores e descreverem as cores foram criados modelos de cores, neste trabalho falaremos sobre o RGB e HSV, pois são os modelos usados durante o desenvolvimento. Modelos de cores são modelos matemáticos utilizados para classificação das cores de acordo com sua tonalidade, saturação, luminosidade ou crominância na tentativa de conseguir cobrir o maior número de cores possíveis e assim simulando a visão. A representação da cor é definida por um único ponto em um modelo tridimensional. Os modelos de cores tem função definir as cores nos programas gráficos de computadores de forma que combine com a percepção das cores pelo sistema visual humano e utiliza três eixos similares para definirem a cor(Leão et al., 2005).

O modelo de cores RGB pode ser considerado mais básico dos modelos de cores. Seu nome possui a mesma definição do espaço de cores RGB. Ele não utiliza de nenhum atributo como luminosidade ou tonalidade, por exemplo, para a definição da cor apenas a adição das cores primárias, azul, verde e vermelho. É este também o padrão mais usado e conhecido. Os valores de R, G e B variam de 0 à 255.

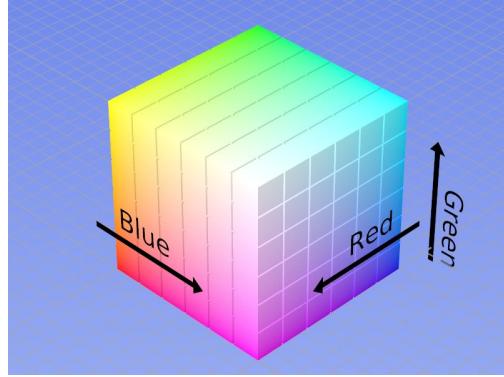


Figura 2.4: Exemplo do Modelo de Cor RGB. Horvath(Horvath,)

O modelo HSV define tonalidade(hue) que é a cor em si, variando de 0 a 360° , a saturação(saturation) que define o grau de pureza da cor, variando de 0 a 1, obtido pela mistura da tonalidade com a cor branca e brilho(value) que tenta fazer referência à percepção humana(Leão et al., 2005) que é a intensidade da cor, escala de tons de cinza(Azevedo and A., 2003), variando também de 0 a 1.

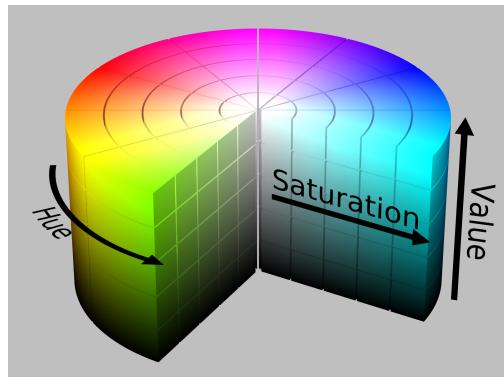


Figura 2.5: Exemplo do Modelo de Cor HSV, Horvath(Horvath,)

O sistema HSV utiliza definições de cor mais intuitivas que o conjunto de cores primárias, por isso são mais adequados quando se necessita obter várias tonalidades.

2.3 Futebol de Robôs

Visto como um domínio bastante complexo, dinâmico e imprevisível(Costa and Pegoraro, 2000), o futebol de robôs surgiu como uma tentativa de promover pesquisas nos campos de Inteligência Artificial e robótica, pela avaliação teórica, algoritmos e arquiteturas por meio de problemas padrão(Kitano et al., 1997). A Equipe Cedro se enquadra na categoria IEEE Very Small Size Soccer. Esta categoria é regulamentada pelo Instituto de Engenheiros Eletricistas e Eletrônicos(IEEE) e possui regras baseadas na MiroSot(da Rosa, 2015). O futebol

de robôs se assemelha ao futebol humano onde o objetivo do jogo é fazer gols para vencer a partida, porém tendo regras adaptadas para o âmbito robótico. Rosa(da Rosa, 2015) em seu trabalho de graduação faz uma boa enumeração das regras básicas:

- A partida dura 10 minutos com dois tempos de 5 minutos;
- Há um intervalo de 10 minutos entre um tempo e outro;
- Cada time tem direito a dois tempos de 2 minutos que podem ser pedidos a qualquer momento;
- Caso a diferença de gols entre os dois times chegue a 10 a partida é encerrada;
- Uma falta ocorre quando há mais de um robô de um mesmo time dentro de sua própria área de gol ou quando um robô empurrar outro robô de outro time;
- Um pênalti ocorre quando a bola fica mais de 10 segundos dentro de alguma das áreas;
- Um chute-livre ocorre quando os robôs ficam travados por mais de 10 segundos, caso ocorra, o juiz posiciona a bola na marca de chute-livre mais próxima de onde ela ficou parada e posiciona os robôs de cada time equidistantes a bola;
- A cada inicio de partida ou gol feito a bola deve ser posicionada no centro do campo e os robôs devem ser posicionados de acordo com a posse de bola.

Capítulo 3

Desenvolvimento

Para o desenvolvimento foi escolhida a biblioteca OpenCV por ser OpenSource, multiplataforma, conter uma grande quantidade de métodos e algoritmos já implementados e pelo seu rápido desempenho de máquina. A linguagem escolhida para o desenvolvimento foi o C++ pois é uma linguagem de programação compilada, o que torna sua execução mais rápida que as linguagens interpretadas, dando ao sistema uma performance em tempo satisfatório.

3.1 Tecnologias Usadas

Para realização deste trabalho, irei utilizar a biblioteca de processamentos de imagens conhecida como OpenCV: Open Source Computer Vision Library. O trabalho será elaborado na linguagem C++, com uso do framework Qt para sua interface gráfica. Os passos detalhados do projeto e seu desenvolvimento estarão presente na seção Projeto, deste mesmo capítulo.

OpenCV Lançado em 1999 pela Intel(Culjak et al., 2012), com objetivo de ser otimizada, portável e com um grande número de funções, o Open Source Computer Vision Library, OpenCV, se tornou se tornou uma ferramenta que possui mais de 2500 algoritmos e 40 mil pessoas em seu grupo de usuários(Culjak et al., 2012). Já possui interface para as linguagens C++, C, Python e Java além de suporte para as principais plataformas com Windows, Linux, Mac OS, iOS e Android. A biblioteca lida tanto com imagens em tempo real, como vídeos e imagens estáticas.

Qt Qt é um framework de desenvolvimento de aplicações multiplataforma. Entre suas funcionalidades está a possibilidade de criar interfaces gráficas diretamente em C++ usando seu módulo Widgets.

C++ A linguagem de programação C++ foi projetado por Bjarne Stroustrup para fornecer eficiência e flexibilidade da linguagem C para programação de sistemas. A linguagem evoluiu a partir de uma versão anterior chamado C com Classes, o projeto C com Classes durou entre 1979 e 1983 e determinou os moldes para o C++. A linguagem foi oficialmente lancada em 1986(Stroustrup, 1996).

3.2 Projeto

3.2.1 Organização do Projeto

O projeto foi desenvolvido seguindo o paradigma de programação Orientada à Objetos, esse paradigma baseia-se na utilização de objetos individuais para criação de um sistema maior e complexo. A IDE usada para o desenvolvimento foi a QT Creator, esta separada o projeto em três pastas: Headers, Sources e Forms. Na pasta Headers estão os arquivos de cabeçalho(.h), onde estão as declarações dos métodos e variáveis usados nas classes executáveis. Já na pasta Sources estão os arquivos fonte(.cpp), são nesses arquivos que os métodos declarados nos arquivos da pasta Header são implementados. Na pasta Forms está o arquivo de interface gráfica(.ui) que é usado no projeto para ser a ponte entre o usuário e as funções do sistema.

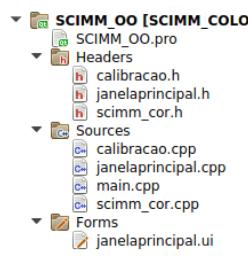


Figura 3.1: Organização das pastas do projeto

Com exceção do arquivo fonte `main`, cada arquivo de cabeçalho possui um arquivo fonte correspondente, formando assim um objeto, todo objeto é uma classe mas nem toda classe forma um objeto. As classes desenvolvidas no projeto são: `Calibração`, `scimm_cor` e `janela-principal`.

3.2.2 Classes

`main`

Esta é o que se chama de *ponto de entrada* em programação. *Ponto de entrada* é onde o sistema operacional irá iniciar a execução do sistema desenvolvido. Esta classe possui somente o método `main` e este instancia e inicia o objeto `JanelaPrincipal` que apresenta a interface gráfica para interação com o usuário.

`JanelaPrincipal`

É uma classe-objeto que utiliza da implementação de objetos `QWidget` e suas subclasses disponíveis pelo framework Qt, para a criação de uma interface gráfica que faz a interação com o usuário. Todos os métodos presentes nessa classe são para utilização gráfica, comportamento de botões e menu de seleção, para a comunicação com a classe de calibração.

Calibracao

É classe que contem todos os métodos e variáveis usados no processo de calibração, é também dentro dessa classe que são feitas todos os tipos de manipulação em imagem.

Os métodos contidos na classe Calibração são:

Iniciar: Método onde é instanciado o objeto que faz referencia à **JanelaPrincipal**, para ser usado quando houver necessidade de comunicação com a interface que não seja por meio de retorno, este método também é onde se inicializa o a câmera, a partir do id contido na interface, e se verifica se a mesma esta disponível.

ConfigurarCamera: Método onde a imagem de exibição é ajustando o tamanho da tela a ser usada durante a detecção de objetos, além do ajuste de brilho e contraste para tornar mais nítido os contornos durante a detecção de objetos.

ReconhecerFundoExtrairObjetos: Método onde se utiliza o algoritmo de subtração de fundo para identificar, inicialmente, o campo e uma vez identificado se separa os objetos que não fazem parte do fundo inicial, a extração dos objetos. A extração dos objetos gerando uma imagem *máscara* que sera usada na detecção dos objetos para que a mesma ser executada com mais precisão, uma vez que os objetos coloridos eram os únicos que não fazem parte da imagem inicial, o fundo.

Calibrar: Método onde se a imagem atual da câmera é obtida e ajustada de acordo com os parâmetros estabelecidos no método **ConfigurarCamera** e iniciado o método **DetectarObjetos**. Uma vez que os objetos foram identificados se faz o uso do método **Calcular** para serem analisados os valores de cada pixel de cada objetos e estes classificados de acordo com as cores pré definidas pelo sistemas. Uma vez terminado o processo de calibração é exibida na tela para o usuário os objetos da cor que esta selecionada no menu de cores.

DetectarObjetos: Método onde serão aplicados filtros de diminuição de ruído, detectadas as bordas existentes na imagem, detectados os objetos a partir das bordas contidas na imagem, o aumento da precisão do contorno dos objetos e diminuição do tamanho do objeto de acordo com a porcentagem de borda a ser eliminada.

ObterPorcentagem: Método simples para devolver a porcentagem de um valor, ao ser informado o valor e a porcentagem escolhida.

Calcular: Método onde cada pixel pertencente à cada um dos objetos encontrados é analisado, seu valor H é categorizado de acordo com as cores pre-definidas no sistema e adicionado à cor correspondente. O algoritmo de categorização:

SCIMM_COR

Classe de cor utilizada do sistema. Onde são salvos os valores máximos e mínimos de HSV. Possui seis valores, um mínimo e um máximo para H, S e V.

3.3 O Sistema

O sistema consiste na apresentação da **interface gráfica** simples e objetiva. Possuindo seis botões, um menu de escolha e uma janela de exibição. A Figura 3.2 exemplifica o fluxo do sistema, que se constitui em cinco etapas e os mesmos possuem o mínimo de ação possível do usuário.

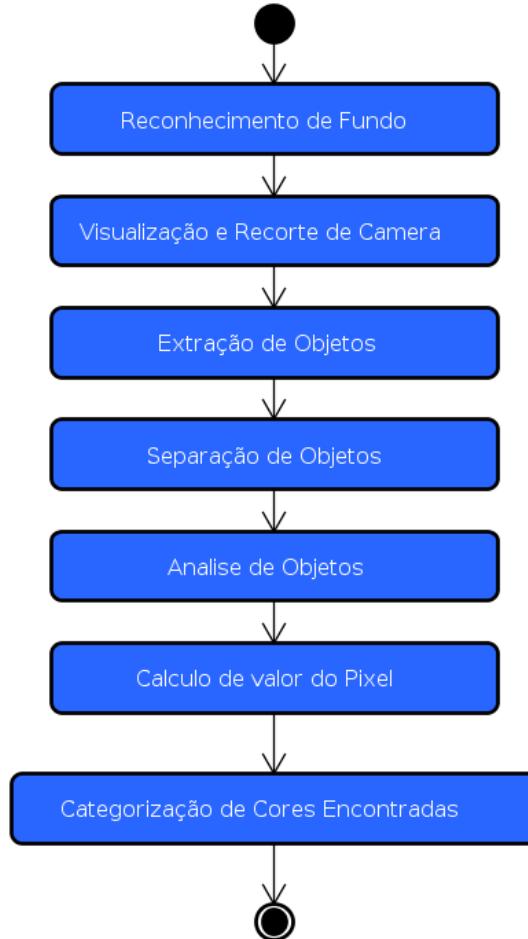


Figura 3.2: Diagrama de Fluxo

Nas subseções à seguir explicarei detalhadamente cada uma das etapas do processo de calibração automática.

3.3.1 1^a Etapa - Configuração de Camera

Para melhor desempenho do algoritmo de detecção de objetos, a imagem é recortada somente para o tamanho necessário do campo. O recorte de imagem foi feito utilizando a função `setMouseCallback` para possibilitar a interação do usuário na imagem por meio do mouse, sua utilização é dada da seguinte maneira:

```
cv::setMouseCallback(src_window,mouseHandler,0);
```

Tem como primeiro parâmetro **src_windows** que indica a janela na qual a função receberá a interação, o segundo, **mouseHandler**, indica a função na qual esta implementada a interação e o ultimo parâmetro, **0**, indica parâmetros opcionais, neste caso não usaremos nenhum então foi usado o numero 0. Dentro da função **mouseHandler** são identificados os pontos iniciais e final da seleção na tela e utilizada a função *rectangle* para demarcar a seleção na tela. A utilização da função *rectangle* completa fica da seguinte maneira:

```
cv::rectangle(frameA, point1, point2, CV_RGB(255, 0, 0), 2, 5, 0);
```

A função recebe os parâmetros **frameA** indicando a imagem na qual será demarcada a área selecionada, depois o parâmetro **point1** que é o ponto inicial de seleção na imagem, **point2** que é o ponto final da seleção. **CV_RGB(255, 0, 0)** que indica a cor da demarcação, **2** indicando a espessura da demarcação, **5** que significa o tipo de linha a ser utilizado na demarcação e **0** que é o numero de bits fracionários.



Figura 3.3: Configuração de Camera

Após confirmada a escolha do tamanho da tela este é então salvo na variável nomeada *tamanho*, está então sera usado durante todo o processo de calibração. Além de recorte da imagem, nessa etapa também são configurados Brilho e Contraste de forma que os objetos de cor no campo se tornem mais vividos, se tornando assim também mais nítidos, para que os processos de separação e detecção de objetos sejam mais precisos. A configuração de Brilho e Contraste utiliza o método *convertTo* da biblioteca *OpenCV* que é utilizada para o melhoramento da imagem antes da detecção dos objetos, a utilização completa fica da seguinte maneira:

```
frameA.convertTo(frameA, -1, contrast_value / 50.0, brightness_value)
```

Esta função recebe quatro parametros. O primeiro **frameA** informa aonde sera salvo o resultado da conversão. O segundo **-1** indica o tipo da matrix, ou numero de canais, da imagem a ser gerada, usa-se **-1** quando se deseja que se use os valores semelhantes aos da imagem da imagem original(itseez,), O terceiro **contrast_value / 50.0** indica o valor de contraste, ou alpha, a ser usado para multiplicar os valores do pixel da imagem(itseez,) e por ultimo **brightness_value** que é o valor do brilho, ou beta, a ser adicionado à imagem. É importante ressaltar que a configuração de Brilho e Contraste é somente usada para a

melhor precisão na detecção dos objetos, no momento da análise do pixel, a imagem está *limpa* sem alguma alteração.

3.3.2 2^a Etapa - Reconhecimento de Fundo

Um principais problemas que ocorrem na detecção de objetos é a confusão do fundo junto ao próprio objeto, fazendo assim que o mesmo seja detectado porém não seu contorno correto, ou em outras vezes ignorado por ser considerado parte do fundo. Para eliminar este problema foi utilizado a técnica Subtração do fundo usando Mistura de Gaussianas, por meio do objeto *createBackgroundSubtractorMOG2()* disponível na biblioteca *OpenCV*. Esta técnica utiliza um algoritmo de análise pixel a pixel e que classifica o mesmo baseando-se na distribuição da gaussiana que o representa. Para separar o fundo do resto da imagem é levada em consideração que a gaussiana que representa o fundo tenha grande peso e baixa variância, isso significa que a mesma ocorre frequentemente e varie pouco no tempo. O algoritmo atualiza o modelo de fundo a cada quadro da imagem baseando-se na variância do objetos da mesma e de sua variância. O objeto criado pela biblioteca, por meio do método **apply**, analisa quadro a quadro a imagem, a compara com o fundo obtido e gera uma imagem chamada de **máscara** com os objetos que não fazem parte do fundo, no exato momento da imagem, com o passar dos quadros o objeto se torna parte do fundo. Uso do método:

```
pMOG2->apply(frame, mask);
```

Onde **frame** significa a imagem atual capturada pela câmera e **mask** a máscara gerada pela diferença da imagem atual com o modelo de fundo.

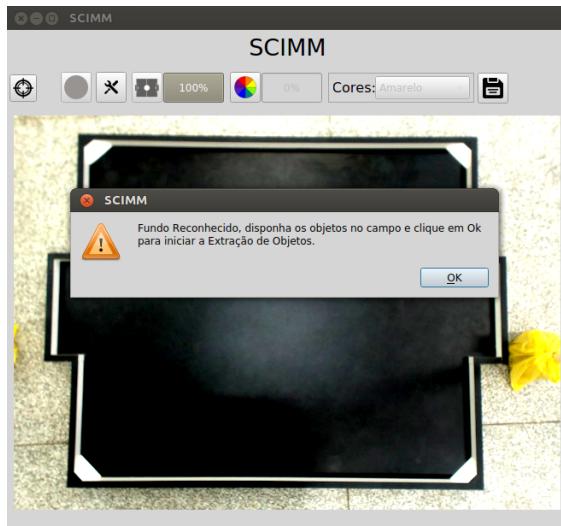


Figura 3.4: Configuração de Camera

Sabendo inicialmente que o modelo de fundo do objeto **pMOG2** esta vazio, basta que ele seja executado algumas vezes para que o campo se torne o modelo de fundo. Nesse caso a máscara gerada pelo método não chega a ser utilizada, porém sera na 3^a etapa.

3.3.3 3^a Etapa - Extração dos Objetos do Fundo

Como visto na 2^a etapa, o objeto **pMOG2** chamando o método *apply* gera uma máscara de diferença da imagem atual para o modelo de fundo. Sendo assim para obtermos os objetos que virão a ser detectados basta que o método *apply* seja chamado um numero de vezes suficiente para criar a máscara e o mesmo não alterar o modelo de fundo.



Figura 3.5: Geração de Máscara

3.3.4 4^a Etapa - Detecção e validação de Objetos

A detecção dos objetos a serem calibrados é dada pelo algoritmo de detecção de bordas de Canny. Como mais um recurso para eliminação de ruídos e melhoria da imagem antes de ser executado a detecção de objetos por meio da detecção de bordas é utilizado desfoque na imagem. O algoritmo de Canny já está implementado dentro da biblioteca OpenCV e com a seguinte usagem:

```
Canny(src_gray, canny_output, limiar, limiar * 3, 3);
```

O algoritmo de Canny utiliza por padrão imagem em padrões de cinza, sendo assim **src_gray** é a imagem original transformada para escala de cinza, esta é a imagem na qual o algoritmo sera aplicado. **canny_output** será a imagem de saída da função. **limiar** e **limiar*3** são os limites mínimos e máximos para considerar uma borda. **3** é o valor de apertura ou kernel, o valor 3 é utilizado como padro.

Apos o uso do algoritmo de Canny para detecção de bordas é necessário então fazer uso da função *findContours*, nativa no *OpenCV* para detecção de contornos.

```
findContours(canny_output, contours, hierarchy, CV_RETR_EXTERNAL,
CV_CHAIN_APPROX_SIMPLE, Point(0, 0))
```

O primeiro parametro, **canny_output**, é a imagem que o algoritmo de Canny gerou com as bordas encontrada na imagem, e é a imagem que o método *findContours* ira utilizar para detectar os contornos, **contours** é o parametro que indica onde serão salvos os contornos

encontrados, cada contorno é armazenado como sendo um vetor de pontos(itseez,). **hierarchy** é onde será salva um vetor de informações sobre a topologia da imagem, e terá como total de elementos o mesmo numero que o total de contornos encontrado(itseez,). O quarto parametro, **CV.RETR_EXTERNAL** indica o modo de obtenção de contornos, nesse caso **CV.RETR_EXTERNAL** indica que o metodo só obterá os contornos exteriores(itseez,). **CV_CHAIN_APPROX_SIMPLE** indica o metodo que sera usado para aproximação de contornos, o metodo **CV_CHAIN_APPROX_SIMPLE** comprime segmentos horizontais, verticais, diagonais e deixa apenas os seus pontos finais(itseez,). E o ultimo parâmetro, **Point(0, 0)**, indica o valor a ser usado para deslocar a imagem ao encontrar os objetos, neste caso esse valor é 0 para Y e 0 para X, pois não sera necessário.

Uma vez obtidos os contornos é necessários que se faça a eliminação de vértices dos polígonos encontrados nos objetos deixando assim o objeto mais preciso. Isso é necessário para deixar a forma encontrada mais precisa dà forma original. Para este ajuste foi usado o método *approxPolyDP*, já implementado dentro da biblioteca OpenCV. Esse método teve que ser aplicado em cada um dos contornos encontrados, e foi utilizado da seguinte maneira:

```
approxPolyDP(Mat(contours[i]), contours_poly[i], 3, true)
```

Onde o metodo inicia recebendo como parâmetro, **Mat(contours[i])** que é a criação de uma nova imagem, somente com aquele unico objeto, que esta sendo analisado. A seguir é informado no segundo parametro a variavel de destino **contours_poly[i]**, onde sera salvo o objeto com a eliminação dos vertices. O terceiro parametro indica o valor do *epilson*, usado o valor **3** que especifica a precisão da aproximação, a distância máxima entre a curva original e a sua aproximação(itseez,). O ultimo parâmetro indica se a curva aproximada sera fechada ou não, foi usado o valor **true** pois neste caso fechar um uma curva é necessário para que o objeto onde está a cor, seja identificado e analisado na probabilidade. Por ultimo os objetos possuem sua borda ignorada, sendo assim calculado o tamanho interior dele, para que por ventura não hajam pixeis de cor preta ou derivadas a serem calculadas.

3.3.5 5^a Etapa - Classificação do Pixel

Para que possam ser feita classificação do pixel é necessário que se faça, primeiramente a conversão da imagem obtida pela câmera, normalmente no espaço de cores RGB, para o espaço de cores HSV, pois a mesma lida melhor com diferenças de luminosidade. A biblioteca **OpenCV** converte o espaço de cor usando a função *cvtColor* que utiliza da imagem original, e de uma imagem vazia com memoria alocada para ser salva a imagem apos a conversão, além do parâmetro do tipo de conversão, Exemplo do uso do método:

```
cvtColor(frame, HSV, CV_RGB2HSV);
```

Apos a conversão é necessário, então, ser feita uma analise dos objetos encontrados. Para cada objeto serão todos os seus pixeis, cada pixel separadamente o mesmo categorizado de acordo com o intervalo de valores ta tabela a baixo:

Cor	Intervalo de H
Laranja	de 0 à 20
Amarelo	de 21 à 30
Verde	de 61 à 90
Azul	de 91 à 120
Roxo	de 125 à 160
Rosa	de 161 à 168
Vermelha	de 169 à 180

Tabela 3.1: Intervalo de Valores de Cores - HSV

Estes valores foram obtidos por meio da conversão dos valores de cada cor no universo real para dentro da biblioteca OpenCV. Como visto na sessão 2.2 Cores da fundamentação teórica, o intervalo de valores da matiz(h) é de 0° a 360° , dentro da biblioteca o intervalo é dado entre os pelo intervalo de números inteiros de 0 à 180 . Uma outra ressalva deve ser feita quando à conversão de valores. Como não há pre-definição destes valores disponível pela biblioteca, foi feito então testes utilizando os valores considerados no mundo real como base para que chegássemos a esses valores.

Durante o desenvolvimento foi observado que, em sua maioria, as cores necessitavam de um valor S e V pré estabelecido. Para as cores Laranja, Azul, Rosa e Vermelho foi pré estabelecido o valor de 100 para ambos, S e V. A cor Amarelo usa a pré definição de S e V com o valor. A cor Verde é a única que possui os valores pré definidos diferenciados um do outro, tendo 30 para S e 50 para V. Já a cor Roxo possui tanto para S quanto para V o valor 30.

3.3.6 6^a Etapa - Gerar Arquivo de Cores

Assim que todas as cores já estiverem sido assimiladas e a calibração finalizada, gera-se um arquivo chamado **cores.arff**, contendo 14 linhas. Sabendo que o sistema calibra 7 cores o arquivo é gerado com o dobro de linhas da quantidade de cor, de modo que a primeira designe o valor mínimo HSV e a segunda o valor máximo para cada cor.

Capítulo 4

Testes e Resultados

Este capítulo será dividido em duas seções: **Calibração** e **Testes**. A seção **Calibração** terá a descrição do processo de calibração de cores, a preparação do campo, configuração de imagem, etc. A seção **Testes** é onde descrevo o testes usados para a análise de eficiência do sistema desenvolvido.

4.1 Calibração

A calibração aqui descrita ocorreu dia no 19 de Agosto de 2016, entre 17:36 e 17:39. A rotina de calibração do sistema, já descrita no Capítulo 3 deste trabalho, envolve primeiramente uma aquisição da imagem do campo vazio, sem nada no mesmo, como visto na Figura 4.1.

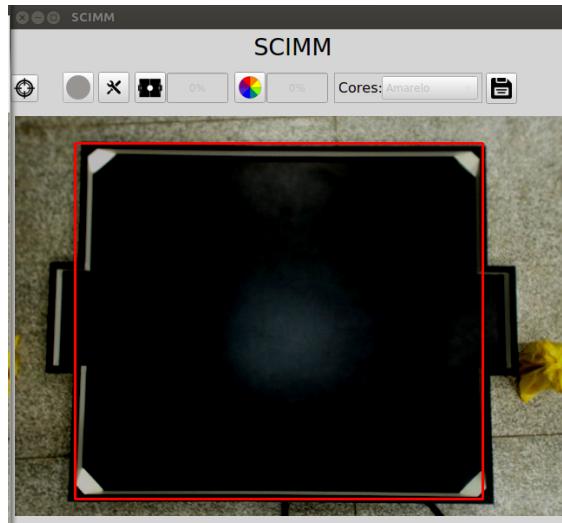


Figura 4.1: Imagem do fundo com a seleção de campo

Após ter o campo identificado pelo sistema, deve-se dispor sobre o campos os objetos coloridos, com as cores cujo se deseja obter o intervalo. É preferido que se usem tiras coloridas, pois quanto maior o tamanho da tira de cor, maior sera o espectro de cores que seja analisado, assim sendo possível uma melhor qualidade de calibração. Neste teste foram

dispostos no campo tiras coloridas com largura entre 17cm e 40cm e altura entre $5,5\text{cm}$ e $10,5\text{cm}$, cada cor com 3 tiras uma vez que o campo foi separado em três partes, significando as partes com diferentes luminosidades, sendo assim cada uma das tiras colocada em uma das partes do campos, como é possível visualizar na Figura 4.2.

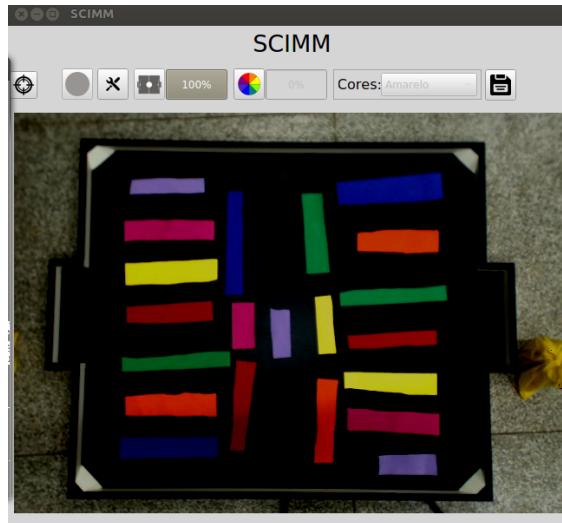


Figura 4.2: Objetos dispostos no campo para calibração

Como resultado da rotina de calibração foi gerado um arquivo .arff contendo 14 linhas. A tabela abaixo possui uma explicação sobre o arquivo gerado. A primeira coluna da tabela designa a linha contida no arquivo, a segunda coluna possui o conteúdo existente na linha do arquivo e na ultima coluna está a descrição do conteúdo do arquivo.

Linha	Conteúdo	Descrição
1	21.50.50	Valor mínimo da cor Amarelo
2	30.255.255	Valor máximo da cor Amarelo
3	92.100.100	Valor mínimo da cor Azul
4	120.255.255	Valor máximo da cor Azul
5	62.30.100	Valor mínimo da cor Verde
6	90.255.255	Valor máximo da cor Verde
7	169.100.100	Valor mínimo da cor Vermelho
8	179.255.255	Valor máximo da cor Vermelho
9	0.100.100	Valor mínimo da cor Laranja
10	20.255.255	Valor máximo da cor Laranja
11	161.100.100	Valor mínimo da cor Rosa
12	168.255.255	Valor máximo da cor Rosa
13	126.30.30	Valor mínimo da cor Roxo
14	160.255.255	Valor máximo da cor Roxo

Tabela 4.1: Os valores de HSV estão separados por pontuação, H.S.V

4.2 Testes

O teste aqui descrito ocorreu dia no 26 de Agosto de 2016, entre à 13:28 e 16:28. Para elaboração do teste optou-se por dividir o campos no maior numero de partes possíveis, e ainda assim que essas partes coubessem todas as 7 cores usadas. Essa divisão foi feita para simular as cores em todas as partes possíveis do campos. O campo foi dividido então em 15 partes de 29cm por 41cm , nomeadas alfabeticamente de A à O, como mostrado na Figura 4.3.

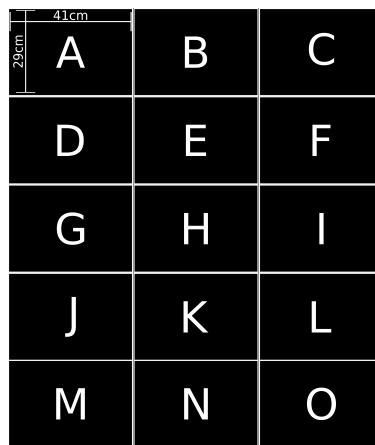


Figura 4.3: Divisão do campo em quinze partes nomeadas alfabeticamente.

Em cada uma das partes do campo estavam dispostas sete cores. Vermelho, Amarelo e Azul na primeira linha. Verde, Roxo, Laranja e Rosa na segunda. As cores estão distantes verticalmente 6cm , na primeira linha a distância entre as cores é de $7,25\text{cm}$ e na segunda linha de 5cm . Um melhor detalhamento da disposição das cores é mostrado na Figura 4.13.

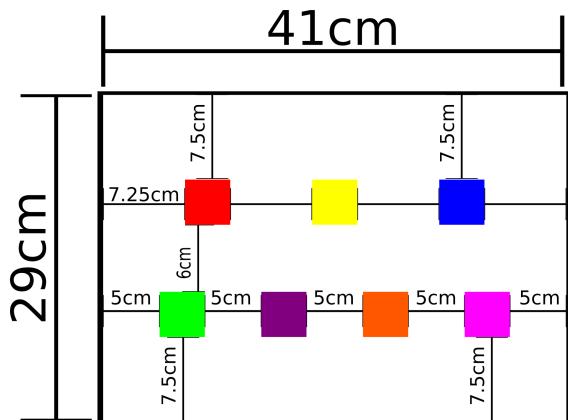


Figura 4.4: Disposição de cada parte quanto as cores



Figura 4.5: Campo após terem sido dispostas as cores

4.2.1 Cores Comuns

Amarelo

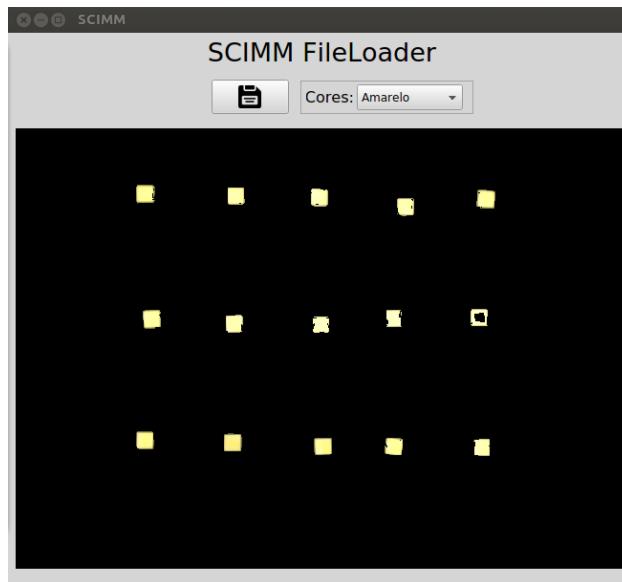


Figura 4.6: Imagem somente com os objetos dentro do intervalo do valor da cor amarela

Dentre os objetos da cor amarela o sistema encontrou quatorze deles completamente e apenas um, que devido a luminosidade implicada em seu centro deixando a tonalidade muito perto do branco, não totalmente preenchido.

Tipo de Objeto	Quantidade	%
Objetos Completos	14	93,33
Objetos Com Falha de Preenchimento	1	6,66
Objetos Com Diminuição de Contorno	0	
Objetos Extrapolados	0	
Objetos Com Diminuição de Área	0	
Objetos Com Falhas Críticas	0	

Tabela 4.2: Categorização Dos Objetos

Dentre as classificações dos objetos as que *Objetos Com Falhas Críticas* e *Objetos Com Falha de Preenchimento* que juntos somam 6,66% dos objetos.

Azul

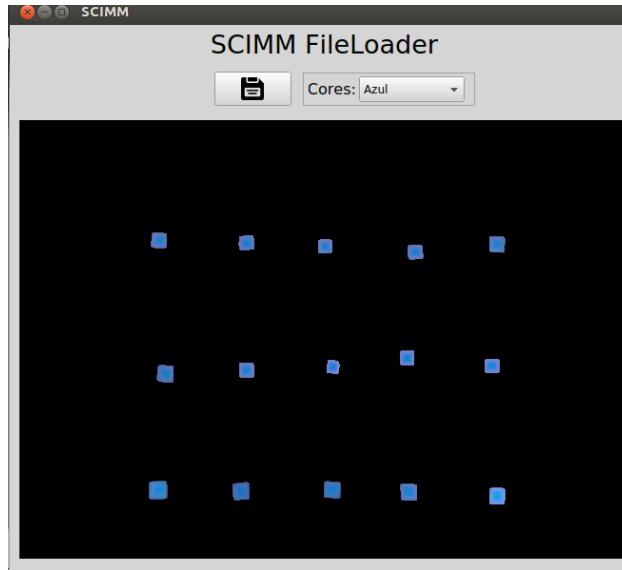


Figura 4.7: Imagem somente com os objetos dentro do intervalo do valor da cor azul

Os objetos da cor azul foram os que obtiveram os melhores resultados, os quinze objetos foram encontrados de forma preenchida. Apesar dos quinze estarem totalmente preenchidos um dos objetos apresentou um tamanho reduzido aos demais devido ao fato de sua borda que não ter sido totalmente detectada.

Tipo de Objeto	Quantidade	%
Objetos Completos	14	93,33
Objetos Com Falha de Preenchimento	0	
Objetos Com Diminuição de Contorno	1	6,66
Objetos Extrapolados	0	
Objetos Com Diminuição de Área	0	
Objetos Com Falhas Críticas	0	

Tabela 4.3: Categorização Dos Objetos

Verde

Figura 4.8: Imagem somente com os objetos dentro do intervalo do valor da cor verde

Os objetos da cor verde foram satisfatoriamente encontrados, com seu preenchimento total e não havendo perda de área devido a qualquer interferência de luz em sua borda.

Tipo de Objeto	Quantidade	%
Objetos Completos	15	100
Objetos Com Falha de Preenchimento	0	
Objetos Com Diminuição de Contorno	0	
Objetos Extrapolados	0	
Objetos Com Diminuição de Área	0	
Objetos Com Falhas Críticas	0	

Tabela 4.4: Categorização Dos Objetos

Rosa

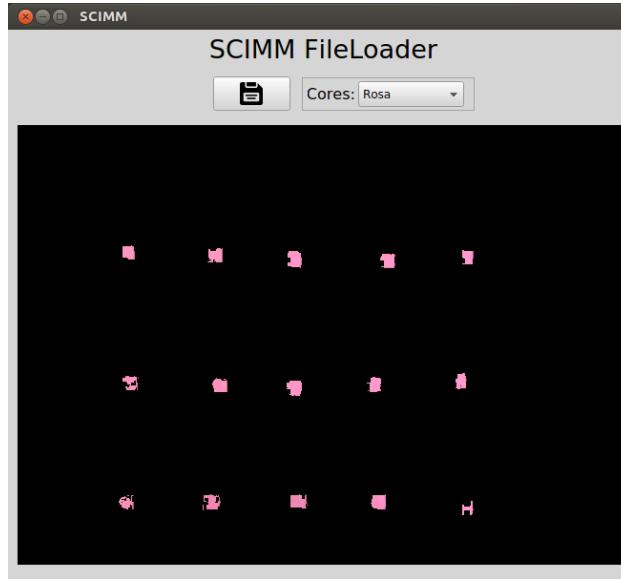


Figura 4.9: Imagem somente com os objetos dentro do intervalo do valor da cor rosa

Dentre os objetos rosa detectados, quatro obtiveram falhas em sua detecção, falhas de preenchimento e diminuição de borda, estes podem ser desconsiderados dos objetos. Dentro os outros onze: três foram detectados sem falhas de preenchimentos apenas com diminuição de sua área para aproximadamente metade da área real do objeto; os outros oito foram encontrados apenas com diminuição de área devido a diminuição de borda.

Tipo de Objeto	Quantidade	%
Objetos Completos	0	
Objetos Com Falha de Preenchimento	0	
Objetos Com Diminuição de Contorno	8	53,33
Objetos Extrapolados	0	
Objetos Com Diminuição de Área	3	20
Objetos Com Falhas Críticas	4	26,66

Tabela 4.5: Categorização Dos Objetos

Dentre as classificações dos objetos as que *Objetos Com Falhas Críticas* e *Objetos Com Falha de Preenchimento* que juntos somam 26,66% dos objetos. Apesar de ser um numero não tão baixo, a cor rosa não é uma cor que a equipe Cedro costuma usar em seus jogos, sendo assim, essa taxa de erro não influencia na eficiência do sistema.

Roxo



Figura 4.10: Imagem somente com os objetos dentro do intervalo do valor da cor roxo

Todos os objetos roxos dispostos no campo foram encontrados pelo intervalo da cor. Dentro os quinze, quatro não apresentaram problema algum e foram completamente detectados; oito possuíram diminuição em seu contorno e três diminuição em sua área relativa.

Tipo de Objeto	Quantidade	%
Objetos Completos	4	26,66
Objetos Com Falha de Preenchimento	0	
Objetos Com Diminuição de Contorno	8	53,33
Objetos Extrapolados	0	
Objetos Com Diminuição de Área	3	20
Objetos Com Falhas Críticas	0	

Tabela 4.6: Categorização Dos Objetos

4.2.2 Cores Com Problemas Conhecidos

Cores como Vermelho e Laranja possuem o problema de por vezes, devido a interferência externas, se assemelharem a outras. Este problemas já são de conhecimento da área.

Vermelho



Figura 4.11: Imagem somente com os objetos dentro do intervalo do valor da cor vermelho

A cor rosa, em determinadas luminosidades pode acabar sendo semelhante a cor vermelha, por este motivo que alguns traços dos objetos rosas estão aparecendo dentro do intervalo de calibração. Porem serão ignorados, uma vez que é possível de ser feito a separação entre as das cores via software.

Tipo de Objeto	Quantidade	%
Objetos Completos	8	53,33
Objetos Com Falha de Preenchimento	1	6,66
Objetos Com Diminuição de Contorno	4	26,66
Objetos Extrapolados	13	
Objetos Com Diminuição de Área	1	6,66
Objetos Com Falhas Críticas	1	6,66

Tabela 4.7: Categorização Dos Objetos

Dentre as classificações dos objetos as que *Objetos Com Falhas Críticas* e *Objetos Com Falha de Preenchimento* que juntos somam somente 13,32% dos objetos.

Laranja

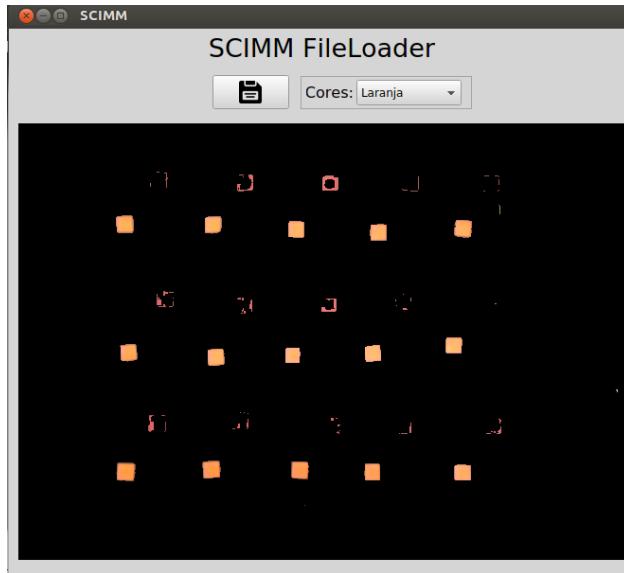


Figura 4.12: Imagem somente com os objetos dentro do intervalo do valor da cor laranja

Devido à um problema muito comum na área de calibração de cores, a cor laranja possui o problema de ser, por muitas vezes, semelhante a vermelha, e devido a luminosidade implicada tanto em uma quanto na outra, ambas as cores tendem a se tornarem próximas. Sabendo deste problema, o fato de terem sido encontrados objetos da cor vermelha dentro do intervalo de valores da cor laranja é ignorado e somente serão levados em consideração os objetos visualmente laranjas. Os quinze objetos da cor laranja foram encontrados com precisão. Todos possuindo seu completo preenchimento e borda.

Tipo de Objeto	Quantidade	%
Objetos Completos	15	100
Objetos Com Falha de Preenchimento	0	
Objetos Com Diminuição de Contorno	0	
Objetos Extrapolados	8	
Objetos Com Diminuição de Área	0	
Objetos Com Falhas Críticas	0	

Tabela 4.8: Categorização Dos Objetos

Totais

De modo total estavam disposto pelo campo 105 objetos coloridos. Destes, 66,7% dos objetos foram encontrados corretamente, 1,9% foram encontrados com falhas de preenchimento, 20% apresentaram perda de contorno, 6,67% apresentaram diminuição da área e 4,76% apresentaram falhas e faltas que prejudicaram totalmente o objeto.

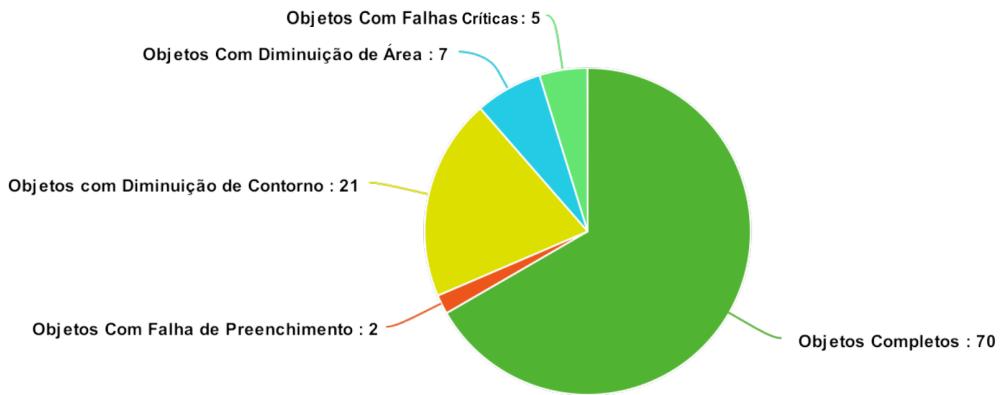


Figura 4.13: Gráfico de análise do resultado dos testes

Sabendo destes valores, os que podem ser considerados críticos na detecção de objetos por meio da sua cor são *Objetos Com Falhas Críticas* e *Objetos Com Falha de Preenchimento* que juntos somam 6,67% dos objetos.

Capítulo 5

Conclusão

5.1 Principais Considerações

Foi realizado um estudo dos modelos de cores dentro da biblioteca OpenCV e identificado que o mesmo não possuía intervalos definidos no padrão HSV. Percebeu-se que uma simples conversão de valores seguindo a teoria das cores não atenderia a necessidade do sistema, sendo que a biblioteca utiliza pixel no formato GBR e não RGB. Deste modo por meio de experimentação e com a ajuda de fóruns especializados, foi definido espectro para cada cor, categorizando o pixel dentre seus respectivos intervalos. Outro aspecto identificado durante o desenvolvimento deste trabalho foi quanto os objetos coloridos usados durante a calibração. Como percebido durante a participação da equipe CEDRO no LARC 2015, a maioria das equipes utilizaram o próprios robôs ou quadrados de aproximadamente $4\text{cm} \times 4\text{cm}$ o que foi identificado neste trabalho que dificultava a detecção e por vezes diminuía o espectro de cores. Por este motivo foi usado tiras de cores com tamanho entre 4 e 10 vezes maior que o utilizado anteriormente. A disposição das tiras no campo também é fundamental no processo de calibração, foi usado uma disposição de 3 tiras por cor, estado elas em cada canto, bem como no meio. O sistema atingiu satisfatoriamente o seu objetivo principal de diminuir o tempo do processo de calibração, tendo reduzido a duração do processo de calibração para apenas um quarto do tempo de *aquecimento*, bem como a automatização da calibração, pois o sistema encontra sozinho os objetos em campo e os categoriza na sua cor adequada. A avaliação dos resultados foi separado em **Calibração e Teste**. Para ambos foram usadas 7 cores: Amarelo, Azul, Laranja, Rosa, Roxo, Verde e Vermelho. A Calibração durou ao todo aproximadamente 5 minutos e gerou o arquivo *cores.arff* contendo os valores HSV mínimo e máximo para cada cor. Para o Teste foi desenvolvida uma aplicação que faz a exibição das cores de acordo com seus valores no arquivo *cores.arff*. A aplicação mostra uma imagem somente com os objetos da cor selecionada, esta imagem é a que foi usada nos testes do Capítulo 4. Cada objeto de cada cor foi categorizado em: Completo; Com Falha de Preenchimento; Com Diminuição de Contorno; Com Diminuição de Área ou Com Falha Críticas. Das categorias de objetos citadas, as que possuem a área do objeto deformada, o que dificulta sua identificação, são *Falha de Preenchimento* e *Falha Críticas*. Somente três cores apresentaram estas falhas: Amarelo, com 6,66%; Vermelho, com 13,33%; e Rosa, com 26,66%. De outro modo, somente uma cor não apresentou objetos completos, a cor Rosa. As cores Amarelo, Azul, Verde e Laranja obtiveram mais de 90% de seus objetos encontrados completamente. A cor Vermelha obteve 53,33% de seus objetos encontrados e o

Roxo 26,66%. Analisando os resultados obtidos pelo sistema, aconselha-se que seja usadas as cores Vermelho, Verde e Roxo para designar os membros de equipe. Quando a cor da equipe, mesmo que tanto Amarelo quanto Azul tenham obtido valores considerados bons, a cor Azul ainda se sobressaiu à Amarela, sendo então indicada para escolha, ao usar o sistema.

5.2 Trabalhos Futuros

Melhorias são indicadas para o sistema tanto na área de detecção de objetos quanto para a categorização de cores. Na detecção de objetos recomenda-se aprimorar a técnica para que não necessitem da subtração de fundo, pois a técnica utilizada neste trabalho infelizmente requer um certo tempo de processamento bem como ação manual, assim sera possível que o sistema se torne 100% automatizado e ainda mais rápido.

Quanto a categorização de cores: a aplicação da técnica também para a cor ciano, bem como melhorar os valos de S e V, uma vez que esses estão sendo usados de maneira estática, seria indicado uma melhoria para que os mesmos sejam os valores detectados das tiras de cor, o que necessita de um certo tratamento.

Outra indicação de incrementação do projeto seria a conversão do sistema para uma biblioteca modular, para que o mesmo possa ser incorporado em diferentes sistemas de estratégia.

Bibliografia

aaaa, aaaa.

Albuquerque and Albuquerque, 2001 Albuquerque, M. and Albuquerque, M. (2001). Processamento de imagens: métodos e análises. *Revista de Ciência e Tecnologia*, 1(1):10–22. Centro Brasileiro de Pesquisas Físicas MCT.

Amit and Felzenszwalb, 2014 Amit, Y. and Felzenszwalb, P. (2014). Object detection. In Ikeuchi, K., editor, *Computer Vision, A Reference Guide*, volume 2, pages 537–542. Springer, New York, NY, USA.

Azevedo and A., 2003 Azevedo, E. and A., C. (2003). *Computação Gráfica: Geração de Imagens*. Elsevier.

Canny, 1986 Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8(6):679–698.

Costa and Pegoraro, 2000 Costa, A. H. R. and Pegoraro, R. (2000). Construindo robôs autônomos para partidas de futebol: o time guaraná. *SBA Controle & Automação*, 11(03):141–149.

Culjak et al., 2012 Culjak, I., Abram, D., Pribanic, T., Dzapo, H., and Cifrek, M. (2012). A brief introduction to opencv. In *MIPRO, 2012 Proceedings of the 35th International Convention*, pages 1725–1730.

da Rosa, 2015 da Rosa, J. F. (2015). Construção de um time de futebol de robôs para a categoria ieee very small size soccer. Trabalho de conclusão de curso, FACULDADE DE DUCAÇÃO TECNOLÓGICA DO ESTADO DO RIO DE JANEIRO.

do Vale and Poz, 2002 do Vale, G. M. and Poz, A. P. D. (2002). O processo de detecção de bordas de canny: Fundamentos, algoritmos e avaliação experimental. In Bergin, T. J. and Gibson, R. G., editors, *Simpósio Brasileiro de Geomática*, pages 292–303.

FIRA, a FIRA. Brief history. Acessado 09/09/2016 22:35.

FIRA, b FIRA. Overview. Acessado 09/09/2016 22:36.

Gonzalez and Woods, 2008 Gonzalez, R. and Woods, R. (2008). *Digital Image Processing*. Pearson/Prentice Hall.

Horvath, Horvath, M. "imagens hsv, hsl e rgb".

Hounslow, Hounslow, K. Tutorial: Real-time object tracking using opencv. Acessado 09/09/2016 20:11.

itseez, itseez. Opencv. Acessado 29/06/2016 16:53.

Kitano et al., 1997 Kitano, H., Asada, M., Kuniyoshi, Y., Noda, I., Osawa, E., and Matsubara, H. (1997). Robocup: A challenge problem for ai. *AI magazine*, 18(1):73.

Leão et al., 2005 Leão, A. C., de Albuquerque Araújo, A., and Souza, L. A. C. (2005). Implementação de sistema de gerenciamento de cores para imagens digitais. In Teixeira, A. C., Barrére, E., and Abrão, I. C., editors, *Web e multimídia: desafios e soluções*. PUC Minas.

Martins et al., 2007 Martins, D. L., Mendes, E. P., Lins, F. C. A., Araújo, M. V. d., Medeiros, A. A. D., and Alsina, P. J. (2007). A versão 2007 da equipe poti de futebol de robôs. In *Team Description Paper. Competição Brasileira de Robótica, Florianópolis, Brasil*.

Nascimento, 2007 Nascimento, M. C. (2007). Detecção de objetos em imagens. Trabalho de graduação, Centro de Informática, Universidade Federal de Pernambuco.

Penharbel et al., 2004 Penharbel, E. A., Destro, R., Tonidandel, F., and Bianchi, R. A. (2004). Filtro de imagem baseado em matriz rgb de cores-padrão para futebol de robôs. *Submetido ao I Encontro de Robótica Inteligente*.

Penharbel et al., Penharbel, E. A., Martins, M. F., Fazolin, A., Gurzoni Jr, J. A., Eduardo, H., Debia, T., Pereira, V. F., Destro, R. C., Tonidandel, F., and Bianchi, R. A. Time de futebol de robôs y04 do centro universitário da fei.

Roth and Winter, 2008 Roth, P. M. and Winter, M. (2008). Survey of appearance-based methods for object recognition. *Inst. for Computer Graphics and Vision, Graz University of Technology, Austria, Technical Report ICGTR0108 (ICG-TR-01/08)*.

Saini et al., 2013 Saini, S., Kasliwal, B., and Bhatia, S. (2013). Comparative study of image edge detection algorithms. *arXiv e-print service in the fields of physics, mathematics, computer science, quantitative biology, quantitative finance and statistics, Cornell University Library*.

SIRLab, SIRLab. Imagens hsv, hsl e rgb. Acessado 06/06/2016 14:50.

Souto, 2003 Souto, R. P. (2003). Segmentação de imagem multiespectral utilizando-se o atributo matiz. Dissertação de mestrado, INPE, São José dos Campos.

Stroustrup, 1996 Stroustrup, B. (1996). A history of c++: 1979–1991. In Bergin, T. J. and Gibson, R. G., editors, *History of programming languages — II*. Addison-Wesley.

Viola and Jones, 2001 Viola, P. and Jones, M. (2001). Rapid object detection using a boosted cascade of simple features. In *Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on*, volume 1, pages I–511. IEEE.

WANGENHEIM, 2014 WANGENHEIM, A. (2014). Von. encontrando a linha divisória: Detecção de borda. *Departamento de Informática e Estatística-Universidade Federal de Santa Catarina, 2013a*, 16.